



Uso de inteligência artificial para auxiliar o combate à obesidade: Estudo de caso em Python

Edjair Aguiar Gomes Filho¹,
Mateus Amorim Silva²,
Leonardo Corsino Campello³,
Ricardo Argenton Ramos⁴,
Braulio Gonçalves Leal⁵

¹Universidade Federal do Vale do São Francisco,
E-mail: edjairaguiar@hotmail.com

²Universidade Federal do Vale do São Francisco,
E-mail: mateus.amorim96@yahoo.com.br

³Universidade Federal do Vale do São Francisco,
E-mail: leo.campello@hotmail.com

⁴Universidade Federal do Vale do São Francisco,
E-mail: ricardo.amos@univasf.edu.br

⁵Universidade Federal do Vale do São Francisco,
E-mail: brauliro.leal@univasf.edu.br

RESUMO: A obesidade, doença crônica não transmissível, é considerada uma epidemia pela OMS. Uma das causas da doença está relacionada aos maus hábitos alimentares. Com o avanço da tecnologia, técnicas têm sido desenvolvidas para auxiliar o combate e a prevenção da obesidade. A inteligência artificial é um dos focos no desenvolvimento de novos métodos que objetivam auxiliar o combate à obesidade. Modelos de redes neurais, campo de estudo dentro da área da inteligência artificial, têm sido propostos devido a capacidade de reconhecer padrões e classificar dados complexos. Este trabalho teve como objetivo principal o desenvolvimento de uma rede neural artificial em Python, utilizando as técnicas de Feedforward e Backpropagation. Através de experimentos, foram coletados dados de 10 indivíduos da quantidade de comida ingerida em cada uma das principais refeições diárias, peso corporal e circunferência abdominal, durante um período de 30 dias. A pesquisa foi realizada em Petrolina, estado de Pernambuco, e Juazeiro, estado da Bahia, com indivíduos de idade entre 18 e 50 anos.

Palavras-chave: obesidade, inteligência artificial, redes neurais, algoritmo

1 INTRODUÇÃO

A obesidade é uma doença definida como o acúmulo excessivo de gordura no organismo [1]. Ela é classificada como uma doença crônica não-transmissível (DCNTs), caracterizando-se por sua evolução lenta, ser assintomática e apresentar causas multifatoriais, sendo algumas delas: genéticas, metabólicas, sociais, comportamentais e/ou culturais [2]. Uma das formas de diagnosticar a obesidade é utilizando o índice de massa corporal (IMC), calculado como a razão da massa corporal pela altura ao quadrado [3].

A Organização Mundial de Saúde considera a obesidade como uma epidemia mundial e a define em três graus de gravidade, baseado no IMC: grau I (moderado excesso de peso), grau II (obesidade leve ou moderada) e grau III (obesidade mórbida) [4].

Embora não exista uma fórmula para combater o aumento gradativo de pacientes com obesidade, algumas medidas vêm sendo tomadas no Brasil buscando minimizar a taxa de pessoas obesas no país [3]. Segundo Dias et al. (2017), as políticas de debate sobre promoção da saúde estão sendo abordadas como forma de instruir a população sobre alimentação adequada e saudável, apesar de não tratar diretamente sobre obesidade.

No ramo da tecnologia, diversos métodos vêm sendo desenvolvidos a fim de auxiliar no combate à epidemia. Dentre essas técnicas, a inteligência artificial (IA) vem sendo aplicada e vista no ramo da saúde como solução inovadora, justamente por incorporar os benefícios da tecnologia e da psicologia, atendendo diferentes necessidades de saúde por meio de várias mídias [5].

É esperado por especialistas da área da computação que os algoritmos de inteligência artificial possam auxiliar os profissionais de saúde, fornecendo dados clinicamente relevantes em tempo real e garantindo a qualidade da informação através de sistemas inteligentes. Isso visa facilitar a obtenção de soluções clínicas e médicas [6]. Ainda segundo Reenita Das (2016), até 2025, espera-se que a IA seja utilizada em 90% dos sistemas nos EUA e em 60% dos hospitais e companhias de seguros globais. A utilização da IA na saúde pode ser justificada pela obtenção de resultados mais precisos para os pacientes, custos reduzidos de tratamento e planos de tratamento centrados no paciente [7].

A inteligência artificial está sendo utilizada no desenvolvimento de novos métodos que objetivam analisar dados estatísticos, aprender e reconhecer padrões e classificar qualquer tipo de dados [8]. Dentro os campos de estudo da inteligência artificial, as redes neurais têm sido alvidradas devido à sua capacidade de reconhecer padrões e classificação de dados complexos. Os modelos de rede neural têm vantagem sobre os métodos estatísticos por serem livres de distribuição e não serem necessários conhecimentos prévios sobre as distribuições estatísticas das classes nas fontes de dados, a fim de aplicar esses métodos para classificação [9].

2 DESENVOLVIMENTO

2.1 ESTUDO DE CASO

Este trabalho trata-se de uma pesquisa correlacional, com abordagem predominantemente quantitativa, utilizando o procedimento técnico de uma pesquisa de campo. O propósito central da pesquisa é o desenvolvimento um algoritmo na linguagem de programação Python, utilizando-se da técnica de redes neurais da inteligência artificial para reconhecer padrões de alimentação. O modelo foi implementado para auxiliar indivíduos adultos na previsão do peso corporal e circunferência abdominal, baseando-se nas informações de alimentação diária, contribuindo para a tomada de decisão em relação à qualidade dos alimentos ingeridos nas refeições. Os dados coletados no experimento foram, então, utilizados no algoritmo de inteligência artificial desenvolvido, apoiado nas técnicas de redes neurais, com o intuito de reconhecer padrões e tentar estimar o peso corporal futuro de indivíduos adultos baseado nos pesos das refeições realizadas diariamente.

2.2 COLETA DOS DADOS

Para a realização da coleta dos dados da pesquisa foram selecionados 10 indivíduos para participar da pesquisa durante 30 dias. Durante este período, foram coletados os seguintes dados: peso das três principais refeições diárias (café da manhã, almoço e jantar), além do peso corporal diário e circunferência abdominal (medidos no início do dia, ao acordar, antes de ir ao banheiro).

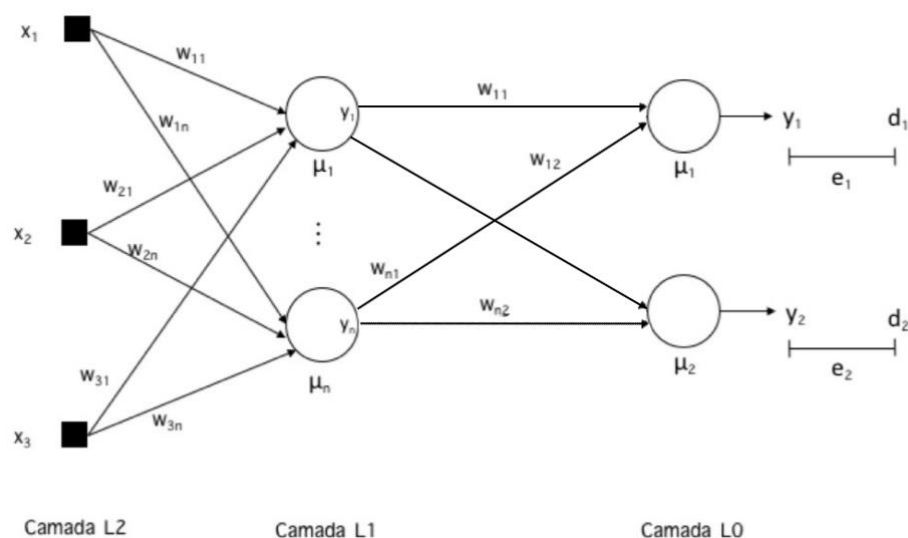
Como instrumento principal para a realização do experimento, foram fornecidas balanças digitais com precisão de duas casas decimais e fitas métricas, sendo uma unidade de cada item para cada indivíduo participante. A pesquisa foi realizada em Petrolina, estado de Pernambuco, e Juazeiro, estado da Bahia. Cada indivíduo participante desta pesquisa foi responsável pela própria coleta dos dados, sendo estes coletados nas próprias residências ou locais de trabalho dos envolvidos. Os dados coletados foram utilizados na aprendizagem do algoritmo.

2.3 DESENVOLVIMENTO DO ALGORITMO

Para implementar o código-fonte foi utilizada a linguagem de programação Python (versão 3.7) que contempla as funcionalidades necessárias para desenvolver o algoritmo. O ambiente de desenvolvimento foi o Spyder (Anaconda 3), no sistema operacional Windows 10 Home.

A RNA proposta neste trabalho foi desenvolvida implementando-se as técnicas de redes neurais *Feedforward* e *Backpropagation* para uso na aprendizagem da rede. Além disso, a arquitetura da RNA utilizada foi de duas camadas (oculta e saída), conforme ilustra a figura 1:

Figura 1 – Arquitetura da RNA implementada



Fonte: Autor

Durante a inicialização do programa, são executadas as primeiras declarações, referentes à configuração da Rede Neural. Essa relação de declarações inclui: número de épocas de treinamento, quantidade de dados que serão usados para treinamento da rede, taxa de aprendizado e a quantidade de neurônios utilizados em cada uma das camadas de neurônios (entrada, camada oculta e saída). A tabela 1 mostra a correspondência de variáveis usadas.

Tabela 1 – Variáveis de inicialização da rede.

Nome da variável	Descrição
<i>numEpocas</i>	Número de épocas de treinamento da rede
<i>q</i>	Quantidade de dados de entrada usados para treinamento
<i>neta</i>	Taxa de aprendizado da rede
<i>m</i>	Quantidade de neurônios na camada de entrada
<i>N</i>	Quantidade de neurônios na camada intermediária
<i>L</i>	Quantidade de neurônios na camada de saída
<i>peso1, peso2 e peso3</i>	Recebem dados das refeições, extraídos do arquivo texto
<i>bias</i>	Parâmetro polarizador de valor 1
<i>Xb</i>	Vetor de entrada da rede
<i>W1 e W2</i>	Matrizes de pesos da RNA

Fonte: Autor

Os valores iniciais dos pesos para cada conexão são gerados de maneira aleatória, utilizando a função *random* da biblioteca *numpy*. Esses valores são alocados matricialmente, de forma que as matrizes são inicializadas com tamanhos correspondentes à quantidade de neurônios nas camadas.

Após isso, os dados de entrada são carregados a partir de um arquivo texto, que contém as informações coletadas durante o experimento, e armazenados nas variáveis correspondentes, sendo as variáveis *peso1*, *peso2* e *peso3* responsáveis por receber os valores de entrada – os pesos das refeições. A variável *d* é um vetor com os dados de saída desejáveis. O último passo das configurações iniciais é concatenar os dados de entrada com o *bias* da rede – elemento utilizado para aumentar o grau de liberdade dos ajustes dos pesos. Essa concatenação é salva na variável *Xb*, que servirá como vetor de entrada da RNA.


A parte de treinamento realiza a chamada das funções responsáveis pelo aprendizado da rede durante *numEpocas* vezes. A técnica de *Feedforward* é implementada para transmitir os dados de entrada através de toda a rede, sendo a saída da camada intermediária a entrada da camada de saída.

Em seguida, chama-se a função responsável por executar o *Backpropagation*: o sinal de erro calculado na saída da rede é propagado no sentido reverso, camada a camada, e ao final deste processo os pesos são ajustados de acordo com a regra de correção de erro. Uma vez que a rede passou pelo processo de aprendizagem, a mesma deve ser testada e validada para confirmar se o resultado obtido é suficiente.

O teste foi realizado utilizando a primeira parte dos dados de entrada, correspondente aos 30 primeiros valores do arquivo texto, e retornando o valor do erro médio obtido na camada de saída. Os dados foram submetidos ao algoritmo de rede neural pouco a pouco, para que fosse possível avaliar o comportamento e aprendizagem da rede. Em cada etapa, algumas variáveis tiveram seus valores modificados, na busca de encontrar a melhor configuração de performance do algoritmo. A taxa de aprendizagem, representada pela variável *neta*, foi variada entre os valores 0.01, 0.05 e 0.10. O número de neurônios da camada oculta variou entre 3 e 15.

Após realizados os testes com diferentes configurações do algoritmo, foi possível perceber que, quanto mais dados inseridos na rede para aprendizagem, maior foi o número de épocas necessárias para convergir e atingir o resultado satisfatório. O algoritmo foi capaz de convergir apenas com quantidade relativamente baixas de dados. Na figura 2, é mostrado o gráfico do comportamento do erro médio durante a etapa de treinamento, desenvolvido dentro do próprio algoritmo utilizando a biblioteca *matplotlib*.

Figura 2 – Erro médio em relação ao número de épocas do treinamento



Fonte: Autor

O treinamento em questão foi realizado utilizando os valores descritos na tabela 2, juntamente às suas respectivas variáveis. A partir dos resultados obtidos, foi possível calcular a diferença entre o valor real e o estimado pela RNA para as variáveis de peso corporal e circunferência abdominal. A menor diferença calculada teve valor de 0.00 e a maior de 2.8. A figura 3 exhibe o teste de erro, calculado durante a fase de teste através de uma subtração entre os valores dos dados de saída obtidos e valores de saída desejáveis.

Tabela 2 –Valores utilizados para o treinamento da figura 3

Nome da variável	Valor utilizado no treinamento
<i>numEpocas</i>	50
<i>q</i>	30
<i>neta</i>	0.05
<i>N</i>	10

Fonte: Autor

Figura 3 – Valores do teste de erro da fase de treinamento

```

[[-0.9 -2. ]
 [-1.6 -2.8]
 [-1.6 -2. ]
 [-1.7 -2. ]
 [-1.1 -1.5]
 [-1.5 -0.5]
 [-1.6 -3. ]
 [-1.4 -1.5]
 [-1.7 -2. ]
 [-1.3 -2. ]
 [-1.4 -3. ]
 [-2. -1.5]
 [-1.2 -1.5]
 [-1.3 -3. ]
 [-1.6 -1. ]
 [ 0.3  0. ]
 [-0.2  0. ]
 [-0.5 -1. ]]

```

Fonte: Autor

À medida que ampliou-se a quantidade de dados utilizada para treinamento, foi possível notar a dificuldade da rede em convergir, apresentando grande quantidade de valores discrepantes (*outliers*), principalmente para a variável de peso corporal, o que é natural devido ao metabolismo do ser humano mudar constantemente. Portanto, apesar da RNA funcionar, é necessário fornecer mais informações na camada de entrada para tornar possível a convergência da rede e reconhecimento de padrões, uma vez considerada a grande heterogeneidade da natureza dos dados.

3 CONCLUSÃO

A partir do trabalho desenvolvido, evidencia-se a importância do uso de novas tecnologias visando a prevenção e o combate à obesidade, afirmada como doença crônica em aumento constante entre indivíduos. Além disso, foi possível atingir o desenvolvimento de um novo algoritmo de rede neural artificial em linguagem Python, com arquitetura de duas camadas ocultas e as técnicas de *Feedforward* e *Backpropagation*, para utilização no processo de aprendizagem do algoritmo.

Entretanto, conclui-se também que ainda faz-se necessário coletar dados de novas variáveis que afetam diretamente o metabolismo do corpo humano e influenciam, principalmente, nos valores de peso corporal, a fim de estimar com maior exatidão a estimativa do peso corporal futuro dos indivíduos. Através das pesquisas realizadas, entende-se que o presente trabalho teve grande potencial de importância para a sociedade em geral, pois disponibiliza mais uma ferramenta que pode contribuir no combate à obesidade, facilitando no controle da alimentação adotada por cada indivíduo.

REFERÊNCIAS

- [1] OLIVEIRA, Cecília L.; FISBERG, Mauro. **Obesidade na infância e adolescência: uma verdadeira epidemia**. Arq Bras Endocrinol Metab [online]. 2003, vol. 47, n.2, pp.107-108. ISSN 1677-9487.
- [2] TAVARES, Telma Braga; NUNES, Simone Machado; SANTOS, Mariana de Oliveira. **Obesidade e qualidade de vida: revisão da literatura**. Revista Médica de Minas Gerais, v. 20, n. 3, p. 359-366, 2010.
- [3] DIAS, Patricia Camacho et al. **Obesidade e políticas públicas: concepções e estratégias adotadas pelo governo brasileiro**. Cad. Saúde Pública, Rio de Janeiro, v. 33, n. 7, 2017. Disponível em: . Acesso em: 30 mai. 2019
- [4] WHO, World Health Organization. **BMI classification**. World Health Organization, Geneva, 2018. Disponível em: http://www.who.int/bmi/index.jsp?introPage=intro_3.html. Acesso em: 29 mai. 2019.
- [5] STEPHENS, Taylor N. et al. **Feasibility of pediatric obesity and prediabetes treatment support through Tess, the AI behavioral coaching chatbot**. Translational Behavioral Medicine, [s.l.], v. 9, n. 3, p.440-447, 16 maio 2019. Oxford University Press (OUP). <http://dx.doi.org/10.1093/tbm/ibz043>.
- [6] REENITA DAS. Forbes. **Five Technologies That Will Disrupt Healthcare By 2020**. 2016. Disponível em: . Acesso em: 06 jun. 2019.
- [7] BOURGUET, Jean-rémi et al. **An artificial intelligence-based approach to deal with argumentation applied to food quality in a public health policy**. Expert Systems With Applications, [s.l.], v. 40, n. 11, p.4539-4546, set. 2013.
- [8] BENEDIKTSSON, Jon A.; SWAIN, Philip H.; ERSOY, Okan K. **Neural network approaches versus statistical methods in classification of multisource remote sensing data**. IEEE Transactions on Geoscience and Remote Sensing, Vancouver, Canada, v. 28, n. 4, p.540-552, jul. 1990.
- [9] FLECK, Leandro et al. **REDES NEURAIS ARTIFICIAIS: PRINCÍPIOS BÁSICOS**. Revista Eletrônica Científica Inovação e Tecnologia, Medianeira, Paraná, v. 1, n. 13, p.47-57, jun. 2016. Disponível em: . Acesso em: 10 jun. 2019.